

**LAPORAN MACHINE LEARNING
DECISION TREE VS NAIVE BAYES**



Disusun Oleh:

Aggra Kurnia Idhan	G1A024003
Aisyah Azzahrah	G1A024033
Anjelia Febiliyanti	G1A024053

Kelas:

Informatika (A)

Dosen Pengampu:

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU**

2026

DESKRIPSI TUGAS

Kamu adalah seorang Data Scientist di startup EduTech. Perusahaan ingin memprediksi "Apakah mahasiswa akan LULUS TEPAT WAKTU atau TIDAK".

Dataset: mahasiswa_lulus.csv - 500 data dengan fitur: IPK, Kehadiran, Jam_Belajar, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, Status_Beasiswa

Tugas kamu ada 3 Bagian:

BAGIAN A: ANALISIS KONSEP (Individu)

Jawab secara essay 1-2 paragraf per soal

1. Jelaskan kapan Decision Tree lebih cocok digunakan dibanding Naive Bayes untuk kasus prediksi kelulusan ini. Beri 2 alasan.

Jawaban :

Decision Tree lebih cocok digunakan ketika interpretabilitas dan transparansi model menjadi prioritas utama bagi institusi atau pihak kampus. Dalam konteks prediksi kelulusan mahasiswa, pihak akademisi atau dosen pembimbing sering kali tidak hanya memerlukan hasil prediksi berupa "lulus tepat waktu" atau "tidak", tetapi juga membutuhkan penjelasan logis mengenai faktor penentu di baliknya. Struktur pohon keputusan (*decision tree*) memungkinkan aturan keputusan divisualisasikan secara langsung ke dalam bentuk diagram alur yang intuitif dan mudah dipahami oleh orang awam.

Alasan kedua adalah kemampuan Decision Tree dalam menangani hubungan non-linear serta interaksi antarfitur yang kompleks secara alami tanpa batasan asumsi distribusi statistik yang kaku. Algoritma ini dapat secara fleksibel memetakan batas keputusan gabungan yang rumit—seperti kombinasi nilai ambang batas tertentu antara IPK, jam belajar, dan tingkat kehadiran—yang sering kali sulit ditangkap secara optimal oleh model probabilistik murni seperti Naive Bayes.

2. Asumsi "independen" di Naive Bayes. Sebutkan 2 pasang fitur di dataset yang kemungkinan melanggar asumsi ini dan jelaskan kenapa.

Jawaban :

Naive Bayes mengasumsikan bahwa semua fitur bersifat independent (saling bebas) secara kondisional terhadap kelas target. Dalam dataset prediksi kelulusan ini, dua pasang fitur yang sangat berpotensi melanggar asumsi tersebut adalah (IPK dan Jam_Belajar) serta (Penghasilan_Ortu dan Status_Beasiswa).

Pertama, IPK dan Jam_Belajar, secara empiris dan logis memiliki korelasi yang kuat, jadi mahasiswa yang mendedikasikan jam belajar lebih tinggi umumnya

cenderung memiliki pencapaian IPK yang lebih baik pula, sehingga keduanya tidak saling bebas. Yang kedua itu, Penghasilan_Ortu dan Status_Beasiswa, juga saling berkaitan erat karena kebijakan penyaluran beasiswa di perguruan tinggi biasanya mempertimbangkan kondisi ekonomi atau tingkat penghasilan orang tua mahasiswa sebagai salah satu variabel penentu utamanya. Mahasiswa dari keluarga berpenghasilan rendah lebih berpeluang menerima beasiswa (karena kriteria seleksi beasiswa sering mempertimbangkan kondisi ekonomi keluarga), sementara mahasiswa dari keluarga berpenghasilan tinggi jarang menerima beasiswa. Kedua fitur ini jelas saling terkait secara sebab-akibat, bukan independen.

3. Apa risiko overfitting pada Decision Tree di dataset ini? Bagaimana cara mengatasinya?

Jawaban :

Risiko utama *overfitting* pada Decision Tree dalam dataset ini terjadi ketika pohon tumbuh tanpa batasan (seperti menggunakan parameter `max_depth=None`) jadi akan terus memecah data hingga setiap daun berisi sangat sedikit sampel, sehingga model terlalu bebas, kompleks, dan cenderung menghafal seluruh detail serta *noise* yang ada pada data latih. Akibatnya, model kehilangan kemampuan generalisasinya, yang ditunjukkan dengan penurunan performa atau akurasi yang drastis ketika dihadapkan pada data baru atau data uji.

Cara mengatasinya :

- Membatasi Kedalaman Pohon (`max_depth`): Mengatur kedalaman maksimal pohon (misalnya dibatasi hingga `max_depth=3`) agar model hanya mempelajari pola utama yang esensial.
- Pengaturan Parameter Daun (`min_samples_leaf` atau `min_samples_split`): Menentukan jumlah minimum sampel yang diperlukan untuk melakukan pemisahan node atau berada pada simpul daun dan tidak terlalu kompleks.
- Pemangkasan (*Pruning*) dan Validasi Silang: Menerapkan teknik *cost-complexity pruning* (seperti parameter `ccp_alpha`) atau menggunakan *cross-validation* guna menyederhanakan struktur pohon tanpa mengorbankan akurasi prediksi pada data validasi.
- Mempertimbangkan metode ensemble seperti Random Forest yang menggabungkan banyak pohon untuk mengurangi varians model.

BAGIAN B : IMPLEMENTASI & EVALUASI (Kelompok)

Gunakan Python + sklearn + pandas + matplotlib

1. Preprocessing: Handle missing value, encoding, train-test split 80:20

Jawaban:

Source Code :

```

1  # M. Mahdianpour Lili (mahdianpour.lili@gmail.com)
2  # BSW View menu RunTime Tools help
3  # Form 1: class = 1 Test 1-2 RunTime -
4
5  from google.protobuf import text_format
6  from google.protobuf import descriptor
7  from google.protobuf import descriptor_pb2
8
9  # Import the descriptor
10  # Import the descriptor
11  # Import the descriptor
12  # Import the descriptor
13  # Import the descriptor
14  # Import the descriptor
15  # Import the descriptor
16  # Import the descriptor
17  # Import the descriptor
18  # Import the descriptor
19  # Import the descriptor
20  # Import the descriptor
21  # Import the descriptor
22  # Import the descriptor
23  # Import the descriptor
24  # Import the descriptor
25  # Import the descriptor
26  # Import the descriptor
27  # Import the descriptor
28  # Import the descriptor
29  # Import the descriptor
30  # Import the descriptor
31  # Import the descriptor
32  # Import the descriptor
33  # Import the descriptor
34  # Import the descriptor
35  # Import the descriptor
36  # Import the descriptor
37  # Import the descriptor
38  # Import the descriptor
39  # Import the descriptor
40  # Import the descriptor
41  # Import the descriptor
42  # Import the descriptor
43  # Import the descriptor
44  # Import the descriptor
45  # Import the descriptor
46  # Import the descriptor
47  # Import the descriptor
48  # Import the descriptor
49  # Import the descriptor
50  # Import the descriptor
51  # Import the descriptor
52  # Import the descriptor
53  # Import the descriptor
54  # Import the descriptor
55  # Import the descriptor
56  # Import the descriptor
57  # Import the descriptor
58  # Import the descriptor
59  # Import the descriptor
60  # Import the descriptor
61  # Import the descriptor
62  # Import the descriptor
63  # Import the descriptor
64  # Import the descriptor
65  # Import the descriptor
66  # Import the descriptor
67  # Import the descriptor
68  # Import the descriptor
69  # Import the descriptor
70  # Import the descriptor
71  # Import the descriptor
72  # Import the descriptor
73  # Import the descriptor
74  # Import the descriptor
75  # Import the descriptor
76  # Import the descriptor
77  # Import the descriptor
78  # Import the descriptor
79  # Import the descriptor
80  # Import the descriptor
81  # Import the descriptor
82  # Import the descriptor
83  # Import the descriptor
84  # Import the descriptor
85  # Import the descriptor
86  # Import the descriptor
87  # Import the descriptor
88  # Import the descriptor
89  # Import the descriptor
90  # Import the descriptor
91  # Import the descriptor
92  # Import the descriptor
93  # Import the descriptor
94  # Import the descriptor
95  # Import the descriptor
96  # Import the descriptor
97  # Import the descriptor
98  # Import the descriptor
99  # Import the descriptor
100 # Import the descriptor

```

[illegible]

Output :

```

***
1. DATA MENANT
=====
Jumlah baris x kolom : (500, 8)

Info tipe data & missing value:
IPK                20
Kehadiran          20
Jam_Belajar        20
Organisasi         20
Penghasilan_Ortu   0
Jenis_Kelamin      0
Status_Basisua     0
Lulus_Tepat_Waktu  0
dtype: int64

Contoh 5 baris pertama:
   IPK  Kehadiran  Jam_Belajar  Organisasi  Penghasilan_Ortu  Jenis_Kelamin  \
0   3.32    93.1      6.3      Aktif      Menengah      Perempuan    
1   3.04    100.0    0.0      Tidak Aktif      Rendah      Perempuan    
2   3.39    65.2      3.1      Tidak Aktif      Menengah      Perempuan    
3   3.79    88.8      2.5      Aktif      Rendah      Laki-laki    
4   2.99    74.2      4.6      Aktif      Menengah      Laki-laki

```

```
Status_Basisuwa Lulus_Tepat_Waktu
0 Ya Tepat Waktu
1 Tidak
2 Tidak
3 Ya Tepat Waktu
4 Tidak Tepat Waktu

=====
2. PREPROCESSING
=====
Missing "DPM" diisi dengan median = 3.185
Missing "Yehadira" diisi dengan median = 82.3
Missing "Jam_Belajar" diisi dengan median = 3.7
Missing "Organisasi" diisi dengan modus = Tidak Aktif

Total missing value setelah dibersihkan: 0
Encoding "Organisasi": {'Aktif': np.int64(0), 'Tidak Aktif': np.int64(1)}
Encoding "Penghasilan_Ortu": {'Menengah': np.int64(0), 'Rendah': np.int64(1), 'Tinggi': np.int64(2)}
Encoding "jenis_kelamin": {'Laki-laki': np.int64(0), 'Perempuan': np.int64(1)}
Encoding "Status_Basisuwa": {'Tidak': np.int64(0), 'Ya': np.int64(1)}
Encoding target 'Lulus_Tepat_Waktu': {'Tidak Tepat Waktu': np.int64(0), 'Tepat Waktu': np.int64(1)}

Jumlah data latih : 400
Jumlah data uji : 100
```

Penjelasan :

Pemrosesan data dimulai dari penghubung Colab ke Drive, pemuatan dataset 500 baris, penanganan *missing value*, hingga *encoding* dan *train-test split* 80:20. Selanjutnya, tiga model (*Decision Tree max_depth=3*, *max_depth=None*, dan *Gaussian Naive Bayes*) dilatih serta dievaluasi menggunakan metrik akurasi, *precision*, *recall*, *F1-score*, dan *confusion matrix*. Terakhir, dibuat visualisasi pohon keputusan serta diagram batang metrik, disertai analisis error pada 5 data uji yang salah diprediksi.

2. Modeling:

Bangun model DecisionTreeClassifier dengan max depth=3 dan max depth=None

Bangun model GaussianNB

Jawabana :

Source Code dan Output :

```

File Edit Code View Test Run Run all
# python3 random_forest.py -i ./data/random.py(1)

#
# 3. MODELING
#
print("x0 = ", x0) # 65
print("x1, score tree")
print("c = ", cv)

models = [
    "Decision Tree (max_depth=3)": DecisionTreeClassifier(
        max_depth=3, random_state=RANDOM_STATE
    ),
    "Decision Tree (max_depth=None)": DecisionTreeClassifier(
        max_depth=None, random_state=RANDOM_STATE
    ),
    "NaiveBayes Naive Bayes": NaiveBayes(),
]

trained_models = {}
predictions = {}

for name, model in models.items():
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    trained_models[name] = model
    pred_list[name], y_score =
    predict_list(name), y_score
    print("#Model " + (name) + " selected diraibib.")

```

```
=====
3. MODELING
=====
Model 'Decision Tree (max_depth=3)' selesai dilatih.
Model 'Decision Tree (max_depth=None)' selesai dilatih.
Model 'Gaussian Naive Bayes' selesai dilatih.
```

Penjelasan :


Tahap *modeling* menginisialisasi dan melatih tiga algoritma klasifikasi—*Decision Tree* (max_depth=3), *Decision Tree* tanpa batas (max_depth=None), dan *Gaussian Naive Bayes*—menggunakan data latih, lalu menghasilkan prediksi pada data uji secara otomatis melalui perulangan (*looping*).

3. Evaluasi: Hitung Akurasi, Precision, Recall, F1-Score untuk ke-3 model.

Buat Confusion Matrix

Jawaban :

Source Code Output :



Penjelasan :

Tahap evaluasi menguji kinerja ketiga model menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*, lengkap dengan laporan klasifikasi dan penyimpanan *Confusion Matrix*. Berdasarkan tabel ringkasan metrik, *Gaussian Naive Bayes* memperoleh akurasi tertinggi sebesar 79% (F1-Score 0.6957), diikuti oleh *Decision Tree* (max_depth=3) sebesar 71%, dan *Decision Tree* (max_depth=None) terendah di angka 66% akibat kecenderungan *overfitting*.

4. Visualisasi:

Plot Pohon Keputusan dengan max_depth=3

Plot perbandingan metrik 3 model dalam bentuk bar chart

Jawaban :

Source Code dan Output :



=====




5. VISUALISASI

Plot pohon keputusan disimpan -> decision_tree_plot.png

Bar chart perbandingan metrik disimpan -> perbandingan_metrik.png

Feature importance disimpan -> feature_importance.png

=====



Penjelasan :

Tahap visualisasi menghasilkan diagram pohon keputusan (plot_tree) untuk melihat aturan model berkedalaman 3 secara transparan, diagram batang (bar chart) untuk membandingkan metrik antar model secara visual, serta grafik *feature importance* guna mengidentifikasi fitur yang paling berpengaruh dalam menentukan prediksi kelulusan mahasiswa.

5. Analisis Error: Ambil 5 data yang salah prediksi. Jelaskan kenapa menurutmu model salah

Jawaban :

Source Code dan Output :

```

# 6. ANALISIS ERROR (5 data salah prediksi)
#
# 6. ANALISIS ERROR (Decision Tree max_depth=3)
#
# Total data salah prediksi (dari model max_depth=3): 20 dari 300 data uji
#
# 5 contoh data yang salah prediksi:
#
# IPK, Kehadiran, Jenis_Kelamin, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, Status_Beasiswa, Luas_Tempat_Waktu, Prediksi, Aktual
# 3.41, 88.8, 2.3, Tidak Aktif, Menengah, Perempuan, Tidak, Tepat Waktu, Tidak, Tepat Waktu
# 3.47, 88.5, 4.1, Tidak Aktif, Rendah, Perempuan, Ya, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.18, 84.8, 3.2, Tidak Aktif, Menengah, Perempuan, Tidak, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.19, 75.1, 5.2, Tidak Aktif, Tinggi, Laki-laki, Tidak, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.77, 52.5, 2.4, Tidak Aktif, Tinggi, Perempuan, Tidak, Tepat Waktu, Tidak, Tepat Waktu, Tepat Waktu
#
# Analisis kualitatif (interpretasi manual, ditambahkan di bagian):
# Banyak error terjadi pada mahasiswa dengan nilai IPK di sekitar
# garis batas (borderline), misalnya IPK < 3.0 atau Kehadiran < 75%,
# di mana kombinasi fitur saling bertentangan (IPK tinggi tapi
# kehadiran rendah, atau sebaliknya).
#
# Decision Tree dangkal (max_depth=3) hanya menggunakan sedikit
# aturan untuk membagi dataset menjadi kelas, yang bisa jadi
# mengakibatkan overfitting/faktor lain di luar dataset (misalnya
# motivasi, kondisi keluarga, dll.) yang tidak tertangkap fitur yang ada.
  
```

```

# 6. ANALISIS ERROR (Decision Tree max_depth=3)
#
# Total data salah prediksi (dari model max_depth=3): 20 dari 300 data uji
#
# 5 contoh data yang salah prediksi:
#
# IPK, Kehadiran, Jenis_Kelamin, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, Status_Beasiswa, Luas_Tempat_Waktu, Prediksi, Aktual
# 3.41, 88.8, 2.3, Tidak Aktif, Menengah, Perempuan, Tidak, Tepat Waktu, Tidak, Tepat Waktu
# 3.47, 88.5, 4.1, Tidak Aktif, Rendah, Perempuan, Ya, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.18, 84.8, 3.2, Tidak Aktif, Menengah, Perempuan, Tidak, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.19, 75.1, 5.2, Tidak Aktif, Tinggi, Laki-laki, Tidak, Tidak, Tepat Waktu, Tepat Waktu, Tidak, Tepat Waktu
# 3.77, 52.5, 2.4, Tidak Aktif, Tinggi, Perempuan, Tidak, Tepat Waktu, Tidak, Tepat Waktu, Tepat Waktu
#
# Analisis kualitatif (interpretasi manual, ditambahkan di bagian):
# Banyak error terjadi pada mahasiswa dengan nilai IPK di sekitar
# garis batas (borderline), misalnya IPK < 3.0 atau Kehadiran < 75%,
# di mana kombinasi fitur saling bertentangan (IPK tinggi tapi
# kehadiran rendah, atau sebaliknya).
#
# Decision Tree dangkal (max_depth=3) hanya menggunakan sedikit
# aturan untuk membagi dataset menjadi kelas, yang bisa jadi
# mengakibatkan overfitting/faktor lain di luar dataset (misalnya
# motivasi, kondisi keluarga, dll.) yang tidak tertangkap fitur yang ada.
  
```

	A	B	C	D	E	F	G	H	I	J
1	IPK	Kehadiran	Jam_Belajar	Organisasi	Penghasilan_Ortu	Jenis_Kelamin	Status_Beasiswa	Luas_Tempat_Waktu	Prediksi	Aktual
2		3.61	80.8	2.3 Tidak Aktif	Menengah	Perempuan	Tidak	Tepat Waktu	Tidak Tepat Waktu	Tepat Waktu
3		3.47	66.5	4.1 Tidak Aktif	Rendah	Perempuan	Ya	Tidak Tepat Waktu	Tepat Waktu	Tidak Tepat Waktu
4		3.18	64	3.2 Tidak Aktif	Menengah	Perempuan	Tidak	Tidak Tepat Waktu	Tepat Waktu	Tidak Tepat Waktu
5		3.19	75.1	5.2 Tidak Aktif	Tinggi	Laki-laki	Tidak	Tidak Tepat Waktu	Tepat Waktu	Tidak Tepat Waktu
6		3.77	57.5	7.4 Tidak Aktif	Tinggi	Perempuan	Tidak	Tepat Waktu	Tidak Tepat Waktu	Tepat Waktu

Penjelasan :

Tahap analisis error mengidentifikasi 5 sampel data uji dengan prediksi kelulusan yang keliru dari model *Decision Tree* ($\text{max_depth}=3$). Kesalahan prediksi ini umumnya terjadi pada data *borderline* atau zona abu-abu, seperti kombinasi nilai IPK tinggi namun tingkat kehadiran atau jam belajar yang rendah, sehingga batasan aturan model gagal menangkap kompleksitas kondisi aktual tersebut.

BAGIAN C : REKOMENDASI & ETIKA (Kelompok)

Buat Laporan + Slide Presentasi 5 slide

1. Rekomendasi Model: Dari 3 model, mana yang kamu pilih untuk dipakai kampus?

Jelaskan dengan data dari Bagian B

Jawaban :

Model yang Dipilih: *Gaussian Naive Bayes*

Penjelasan :

- Akurasi Tertinggi: Berdasarkan tabel evaluasi, *Gaussian Naive Bayes* mencatatkan Akurasi 79% dan Precision 83%, yang merupakan performa tertinggi dibandingkan *Decision Tree* ($\text{max_depth}=3$) sebesar 71% dan *Decision Tree* ($\text{max_depth}=\text{None}$) sebesar 66%.
 - Menghindari Overfitting: Model *Decision Tree* dengan $\text{max_depth}=\text{None}$ terbukti mengalami penurunan performa (overfitting) pada data uji. Oleh karena itu, *Gaussian Naive Bayes* lebih konsisten dan andal untuk diterapkan dalam memprediksi kelulusan mahasiswa secara objektif.
2. Bias & Etika: Fitur "Penghasilan_Ortu" dan "Jenis_Kelamin" rawan bias. Apa dampaknya jika model dipakai untuk beasiswa? Bagaimana mitigasinya?

Jawaban :

Dampak Jika Dipakai untuk Beasiswa: Fitur seperti "Penghasilan_Ortu" dan "Jenis_Kelamin" rawan memicu diskriminasi sistemik. Jika model digunakan untuk seleksi beasiswa, sistem berisiko mempelajari bias historis (misalnya, memperlakukan tidak adil kelompok gender tertentu atau mendiskriminasi mahasiswa dari tingkat penghasilan tertentu), sehingga keputusan beasiswa menjadi tidak objektif dan tidak adil.

Cara Mitigasinya:

- Melakukan Fairness Audit secara berkala untuk mengukur tingkat keadilan model terhadap kelompok demografis yang berbeda.

